

시각-언어 모델 생성 설명문을 활용한 하이브리드 문서 검색*

안호섭¹, 김민규², 김태욱^{†12}

한양대학교 컴퓨터·소프트웨어학과¹, 한양대학교 컴퓨터·소프트웨어학부²

{ghtjq125, kimtaeuk}@hanyang.ac.kr

Hybrid Document Retrieval with VLM-Generated Descriptions

Hoseob Ahn¹, Mingyu Kim², Taeuk Kim^{†12}

Dept. of Computer Science, Hanyang University¹²

요약

최근 비전 기반 문서 검색(Visual Document Retrieval; VDR)에서는 시각-언어 모델(Vision-Language Model; VLM) 검색기가 문서 이미지를 패치 임베딩으로 직접 표현하는 방식을 채택하여 높은 성능을 달성하고 있다. 그러나 이러한 접근은 문서 내 세부 키워드, 희귀 용어, 전문 개념과 같은 명시적 텍스트 단서를 충분히 보존하지 못해, 질의가 요구하는 세부 의미를 정확히 파악하는데 한계가 있다. 본 논문은 앞서 언급한 단점을 보완하기 위해, 범용 VLM의 문서 이해 및 추론 능력으로 생성한 문서 설명문(Description)을 활용하여 비전 기반 문서 검색 모델의 표현을 보강하는 하이브리드 방법을 제안한다. 제안된 방법은 Qwen3-VL-8B-Instruct가 문서 이미지로부터 생성한 세부 문서 설명문의 토큰 임베딩을 기존 이미지 패치 임베딩과 결합(Concatenation)하여 검색 과정에서 시각적 정보와 명시적 의미 단서가 함께 활용되도록 한다. ViDoRe-v2 벤치마크 실험에서 제안 방법론은 이미지 단독 기준선(Baseline) 대비 ColNomic에서 평균 2.7점, Jina에서 6.3점, ColQwen3.5에서 1.7점(NDCG@5)의 점수 향상을 달성하였다. 또한, K-means 압축을 적용한 메모리 효율 중심 설정을 함께 제시함으로써 비압축 방법 대비 53.65%의 메모리를 절감하면서도 유사한 성능을 유지하였다.

1. 서론

문서 검색(Document Retrieval)은 사용자의 질의에 관련성이 높은 문서를 반환하는 태스크이다. 해당 문제는 전통적으로 OCR(Optical Character Recognition)로 문서 내 텍스트를 추출한 뒤 텍스트 검색 모델을 적용하는 방식에 의존하여 왔으나, 문서 인식 품질에 따라 성능이 크게 좌우되며 표·차트 등 시각적 요소의 정보를 온전히 표현하기 어렵다는 한계가 있었다.

시각-언어 모델(Vision-Language Model; VLM)의 발전은 이를 극복하는 새로운 패러다임, 즉 비전 기반 문서 검색(Visual Document Retrieval; VDR)을 탄생시켰다. 일례로, ColPali[1]는 VLM을 문서 인코더로 직접 활용하여 이미지 패치 임베딩과 MaxSim 기반 후기 상호작용(Late-Interaction)을 활용해 OCR 없이 높은 검색 성능을 달성하였으며, 이후 ColQwen, ColNomic, Jina Embeddings[2] 등 다양한 비전 기반 검색 모델들이 제안되면서, 비전 기반 검색이 주류 방법론으로 자리잡게 되었다.

비전 기반 문서 검색 모델은 문서 이미지를 직접 인코딩함으로써 레이아웃, 시각적 배치, 표와 그림 등 문서의 구조적 정보를 효과적으로 활용할 수 있다. 그러나 문서 이미지를 패치 단위의 시각 임베딩으로 표현하는 과정에서 세부 키워드, 희귀 용어, 전문 개념, 수치와 같은 명시적 텍스트 단서는 개별적인 매칭 단위로 보존되기 어렵다. 특히 질의가 이러한 세밀한 단서에 의존하는 경우, 시각적으로 유사한 문서와 실제 관련 문서를 구분하기 어려워질 수 있다. 따라서 시각적 구조 정보를 유지하면서도 문서 내 명시적 의미 단서를 보강할 수 있는 검색 표현이 필요하다.

이러한 한계를 완화하기 위해 최근 연구들은 VLM을 활용하여 문서 이미지의 시각적·구조적 정보를 반영한 설명문(Description)을 생성하고, 이를 검색에 활용하려는 시도를 보이고 있다. 예를 들어 SERVAL[3]은 VLM이 생성한 문서 설명을 텍스트 기반 검색 표현으로 활용함으로써, 해당 방향성의 가능성을 보였다. 그러나 설명문만을 검색 표현으로 사용할 경우 문서 이미지를 자연어로 변환하는 과정에서 세부 시각 단서가 손실될 수 있으며, 전체 설명문을 모두 활용하면 검색 표현의 길이가 증가해 메모리 비용이 커지는 한계가 있다.

본 논문은 이러한 한계를 보완하기 위해, VLM이 생성한 부가 설명문으로 원본 이미지 표현을 완전히 대체하는 대신, 기존 시각 표현의 보완재로 활용하는 방식을 제안한다. 구체적으로, Qwen3-VL-8B-Instruct가 문서 이미지로부터 생성한 설명문을 기존 이미지 패치와 임베딩 수준에서 연결하여, 하나의 확장된 문서 표현을 구성한다. 이를 통해 MaxSim 기반 후기 상호작용 과정에서 검색 모델은 원본 이미지의 레이아웃과 시각적 구조 정보를 유지하면서도, 설명문에 포함된 세부 키워드, 희귀 용어, 전문 개념, 수치와 같은 명시적 의미 단서를 함께 활용할 수 있다.

ViDoRe-v2 벤치마크 실험에서 제안된 방법은 이미지 단독 기준선(Baseline) 대비 NDCG@5 기준 ColNomic에서 평균 2.7점, Jina에서 6.3점, ColQwen3.5에서 1.7점 향상을 달성하였다. 또한, K-means 압축을 적용한 메모리 효율 중심 설정은 기존 문서 설명문 기반 비압축 방법 대비 53.65%의 메모리를 절감하면서도 유사한 검색 성능을 유지하여, 제안 방법이 명시적 의미 단서 보강과 메모리 효율성을 동시에 달성할 수 있음을 보여준다.

† 교신 저자

* 이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (RS-2025-00558151).

2. 관련 연구

비전 기반 문서 검색. ColPali[1]는 VLM을 문서 인코더로 직접 활용하여 OCR 없이 높은 검색 성능을 달성하였다. 이후 ColQwen, ColNomic, Jina Embeddings[2] 등이 다양한 비전-언어 인코더를 백본으로 성능을 개선하였다.

VLM 기반 설명 검색. SERVAL[3]은 OCR 대신 VLM으로 생성한 자연어 설명을 텍스트 검색 모델에 입력하여, OCR 의존 없이 효과적인 문서 검색이 가능함을 보였다. 본 연구는 이르 발전시켜 설명문을 문서 이미지와 임베딩 수준에서 직접 융합한다.

멀티모달 융합 검색. 기존 멀티모달 검색 연구는 주로 점수 수준의 후기 융합에 집중한다. 본 연구는 임베딩 결합(Concatenation)을 통해 후기 상호작용 내에서 두 모달리티를 직접 상호작용하게 한다는 점에서 기존 방법과 차별화된다.

3. 제안 방법

본 논문에서는 비전 기반 검색을 주된 방법으로 채택하고, VLM이 생성한 의미적 문서 설명을 보조 텍스트 신호로 활용하는 하이브리드 검색 방법을 제안한다. 핵심 아이디어는 VLM을 통해 문서 내용을 의미적으로 풍부하게 표현하고, 이를 임베딩 수준에서 비전 임베딩과 융합함으로써 두 모달리티의 상호 보완적 강점을 모두 활용하는 것이다.

3.1 전체 구조

제안 방법의 문서 인코딩은 두 경로로 구성된다. (1) **비전 경로**: 문서 이미지를 검색 특화 VLM (예: Jina, ColQwen 등)에 직접 입력하여 패치 수준의 임베딩을 추출한다. (2) **설명 경로**: 동일한 문서 이미지를 별도의 범용 VLM에 입력하여 의미적 설명 텍스트를 생성하고, 이를 검색 VLM을 통해 텍스트 토큰 임베딩을 추출한다. 두 임베딩을 연결(Concatenate)하여 최종 문서 표현을 구성하고, ColBERT[4] 방식의 MaxSim으로 검색 점수를 산출한다. 검색 점수는 $s(Q, D) = \sum_i \max_j \mathbf{q}_i \cdot \mathbf{d}_j$ 로 정의되며 ($Q=\{\mathbf{q}_i\}$ 는 질의, $D=\{\mathbf{d}_i\}$ 는 문서), 그림 1은 전체 구조를 보여준다.

3.2 VLM 기반 문서 설명 생성

SERVAL[3]이 VLM 생성 설명문의 유효성을 보인 것에 착안하여, 본 연구는 Qwen3-VL-8B-Instruct를 활용하여 문서 이미지로부터 의미적 설명을 직접 생성한다. 본 단계의 목적은 검색 임베딩 생성이 아니라 문서 이미지의 시각적·의미적 내용을 자연어로 충실히 기술하는 것이므로, 검색 특화 VLM과 별도의 범용 instruction-tuned VLM을 설명 생성기로 사용한다. 검색 특화 VLM은 질의-문서 임베딩 정렬에 최적화되어 있는 반면, Qwen3-VL-8B-Instruct는 표·그림·레이아웃과 세부 텍스트 단서를 설명문 형태로 생성하는 데 적합하다. 생성된 설명은 이후 검색 VLM의 텍스트 인코더를 통해 토큰 임베딩 $T = \{\mathbf{t}_1, \dots, \mathbf{t}_m\}$ 으로 변환된다.




그림 1: 제안 방법의 전체 구조. 문서 이미지는 비전 경로(Vision Encoder)와 설명 경로(Qwen3-VL-8B)를 통해 각각 임베딩되며, 연결 후 쿼리 임베딩과 MaxSim으로 검색 점수를 산출한다.

3.3 임베딩 수준 융합 및 K-means 압축

비전 인코더는 문서 이미지를 패치 임베딩 $V = \{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ 으로 인코딩하고, 텍스트 인코더는 VLM이 생성한 문서 설명문을 토큰 임베딩 $T = \{\mathbf{t}_1, \dots, \mathbf{t}_m\}$ 으로 인코딩한다. 본 논문은 성능 중심 설정에서는 설명문 임베딩 T 를 이미지 패치 임베딩에 그대로 결합하고, 메모리 효율 중심 설정에서는 T 를 K-means로 k 개의 클러스터 중심 $C = \{\mathbf{c}_1, \dots, \mathbf{c}_k\}$ 로 압축한 뒤 결합한다.

$$D_{\text{Full}} = [\mathbf{v}_1, \dots, \mathbf{v}_n, \mathbf{t}_1, \dots, \mathbf{t}_m],$$

$$D_{\text{K-means}} = [\mathbf{v}_1, \dots, \mathbf{v}_n, \mathbf{c}_1, \dots, \mathbf{c}_k].$$

4. 실험

4.1 실험 설정

ViDoRe-v2 벤치마크 내부의 4개 부분 데이터셋(biomedical_lectures_v2, esg_reports_human_labeled_v2, esg_reports_v2, economics_reports_v2)에서 실험을 수행하였다. 3종의 검색 특화 VLM모델을 평가하였다: ColNomic(colnomic-embed-vision-v1.5), Jina(jina-embeddings-v4), ColQwen3.5(Qwen3.5-4B). 비교 대상 방법론은 다음과 같다.

- **Image Only**: 비전 임베딩만 사용하는 기준선
- **Text Only**: 설명문 텍스트 임베딩만 사용
- **K-means (Ours)**: 비전 + K-means 압축 텍스트 임베딩 융합

($k=64$), 메모리 효율 중심 설정

• **Full Doc (Ours)**: 비전 + 전체 설명 텍스트 임베딩 융합 질의는 텍스트이며, 평가 지표는 NDCG@5를 사용한다.

4.2 실험 결과

표 1은 각 모델과 방법론 조합에 대해 NDCG@5로 측정된 성능 비교이다. 괄호 안 수치는 Image Only 대비 향상을 나타낸다.

표 1: ViDoRe-v2 벤치마크에서 NDCG@5로 측정된 결과 (%). 괄호 안 숫자는 Image Only 기준선 대비 향상된 점수를 나타내며, 각 모델별 가장 높은 점수는 굵게 표시하였다.

모델	방법	Bio.	Econ.	ESG-H	ESG	평균
ColNomic	Image Only	63.2	55.6	69.2	53.9	60.5
	Text Only	64.5	57.8	66.8	55.8	61.2 (+0.7)
	K-Means (Ours)	64.6	57.2	71.0	58.9	62.9 (+2.4)
	Full Doc (Ours)	63.2	57.0	72.3	58.0	63.2 (+2.7)
Jina	Image Only	61.3	53.1	60.6	52.5	56.9
	Text Only	62.0	53.6	68.6	61.8	61.5 (+4.6)
	K-Means (Ours)	62.1	56.4	67.5	59.0	61.3 (+4.4)
	Full Doc (Ours)	63.5	54.8	72.9	61.8	63.2 (+6.3)
ColQwen3.5	Image Only	65.6	58.7	71.3	57.9	63.4
	Text Only	65.2	56.5	75.1	60.7	64.4 (+1.0)
	K-Means (Ours)	66.1	58.6	77.0	59.1	65.2 (+1.8)
	Full Doc (Ours)	66.4	58.7	77.0	58.1	65.1 (+1.7)

텍스트 및 비전 단서의 상보적 경향. Text Only와 Image Only의 성능 우위는 데이터셋별로 다르게 나타난다. 예컨대 ColNomic은 ESG-H에서 Image Only(69.2)가 우세한 반면, Econ.에서는 Text Only(57.8)가 더 높은 성능을 보인다. 이는 비전 기반 표현 만으로는 다양한 질의 단서를 충분히 포괄하기 어려우며, 명시적 텍스트 단서 보강이 필요함을 시사한다.

Full Doc 기반 성능 중심 설정. Full Doc은 VLM이 생성한 전체 세부 설명 토큰을 압축 없이 이미지 패치 임베딩에 결합하는 성능 중심 설정이다. 이 설정은 Image Only 대비 ColNomic에서 +2.7점, Jina에서 +6.3점, ColQwen3.5에서 +1.7점의 평균 NDCG@5 향상을 보이며, 세 가지 모델 패밀리 모두에서 일관된 성능 개선을 달성하였다. 이는 세부 문서 설명문이 명시적 의미 단서를 효과적으로 보완함을 보여준다.

K-means 기반 메모리 효율 중심 설정. K-means($k=64$)는 세부 설명 토큰을 클러스터 중심으로 압축하여 메모리 사용량을 줄이는 설정이다. 이 방법은 Image Only 대비 ColNomic 2.4점, Jina 4.4점, ColQwen3.5 1.8점의 성능 향상을 달성하면서, Full Doc 대비 53.65%의 메모리를 절감하였다(1,816 vs. 3,919 MiB). 또한 Text Only 대비로도 19.32%의 메모리를 절감하면서 더 높은 평균 성능을 달성하여(1,816 vs. 2,251 MiB), 성능-메모리 효율 간 실용적인 균형점을 제공한다.

표 2: 전체 임베딩 메모리 사용량 비교. 모든 메모리 값 단위는 MiB이고, 감소율은 Full Doc 대비 K-means를 기준으로 계산.

Docs	Image Only	Text Only	K-Means	Full Doc	Reduction Rate
4,544	1,667.52	2,251.00	1,816.18	3,918.52	53.65%

5. 결론

본 논문은 비전 기반 문서 검색 모델의 패치 기반 시각 표현에서 약화될 수 있는 명시적 의미 단서를 보완하기 위해, VLM이 생성한 세부 문서 설명문의 토큰 임베딩을 이미지 패치 임베딩과 결합하는 하이브리드 검색 방법을 제안하였다. 또한 제안 방법을 전체 설명문 임베딩을 그대로 활용하는 성능 중심 설정과, K-means 압축을 적용하는 메모리 효율 중심 설정을 함께 제시하여 성능-메모리 효율 간 Trade-Off를 조절할 수 있도록 하였다.

ViDoRe-v2 벤치마크 실험 결과, 제안 방법은 ColNomic, Jina, ColQwen3.5 모두에서 이미지 단독 기준선 대비 일관된 NDCG@5 향상을 달성하였다. Full Doc 기반 설정은 가장 높은 성능을 보였고, K-means 기반 설정은 Full Doc 대비 53.65%의 메모리를 절감하면서도 성능 향상을 유지하였다. 이는 VLM이 생성한 세부 문서 설명문이 패치 기반 시각 표현을 보완하는 효율적인 의미 단서로 활용될 수 있음을 보여준다.

향후 연구에서는 단순 K-means 클러스터링을 넘어 질의 독립적 또는 질의 적응적 중요도 기반 토큰 선택, 학습 기반 토큰 압축, 문서 설명문 생성 방식 최적화 등을 탐색할 계획이다. 이를 통해 메모리 효율성을 유지하면서도 문서 내 명시적 의미 단서를 더욱 정밀하게 보존하고, 비전 기반 문서 검색 모델의 문서 표현을 보다 효과적으로 강화할 수 있을 것으로 기대한다.

참고 문헌

- [1] M. Faysse *et al.*, “ColPali: Efficient document retrieval with vision language models,” *arXiv preprint arXiv:2407.01449*, 2024.
- [2] M. Günther *et al.*, “jina-embeddings-v4: Universal embeddings for multimodal multilingual retrieval,” in *Proceedings of the 5th Workshop on Multilingual Representation Learning (MRL 2025)*, 2025.
- [3] T. Nguyen *et al.*, “SERVAL: Surprisingly effective zero-shot visual document retrieval powered by large vision and language models,” in *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. 2025, 2025.
- [4] O. Khattab and M. Zaharia, “ColBERT: Efficient and effective passage search via contextualized late interaction over BERT,” in *Proceedings of the 43rd International ACM SIGIR conference*, pp. 39–48, 2020.